

MIA304 · VISIÓN Y
PERCEPCIÓN
COMPUTARIZADA

Food Vision

Avances de la 2.ª etapa

Equipo Nico · Benja

Seguimiento S2 — Clase 8 · 02/05

Problema

De una foto de comida → categoría + estimación nutricional.

Pipeline objetivo: imagen → clasificador → calorías y macros (proteínas, carbohidratos, grasas) por porción.

Dataset · Food-101

Bossard et al., ECCV 2014

101

categorías

75 750

imágenes train

25 250

imágenes test

750/250

train / test por clase

Resolución típica ~512×512 px · normalizada a 224×224 (ImageNet)

EfficientNet-Bo · Transfer learning head-only

¿Por qué EfficientNet-Bo? 4.1 M params vs 25.6 M (ResNet50) · mejor ratio accuracy/cómputo · ideal para entrenar en hardware local (Apple Silicon MPS)

Imagen 224×224×3

normalización ImageNet

EfficientNet-Bo (congelado)

1280-dim avgpool

Dropout(0.3) → Linear(1280→101)

única parte entrenada

Top-K predicciones

softmax sobre 101 clases

Configuración

Optimizer	Adam · lr 1e-3
Loss	CE + label smoothing 0.1
Épocas	5
Batch size	64
Hardware	Apple Silicon · MPS
Parámetros entrenables	129 829 (3 % del total)

RESULTADO BASELINE

56.3 %


Top-1 val

80.8 %

Top-5 val

Descongelado de los últimos 3 bloques + cabeza

Fase 2 · arranca desde baseline.pt · LR diferenciales · AdamW · CosineAnnealingLR · 25 épocas



Curvas de pérdida y accuracy — Notebook 03

1e-4

lr backbone

1e-3

lr cabeza

25

épocas

1e-4

weight decay

79.4 %

entrenables

Por qué descongelar

Las primeras capas ya capturan bordes/texturas; las últimas se especializan en comida.

Por qué LR distintos

Backbone 1e-4 (preserva representaciones de ImageNet) · cabeza 1e-3 (continúa desde baseline.pt, ya orientada al problema).

Por qué label smoothing

Reduce overconfidence y mejora la calibración para el umbral de confianza.

Por qué Cosine LR

Decae suavemente · ayuda a estabilizar las últimas épocas (mejor val a la 23).

Mejor época

23 / 25

checkpoint guardado · weights/model_v1.pt

De la clase predicha a las calorías estimadas

Módulo desacoplado del modelo · recibe el nombre de clase predicha y devuelve kcal + macronutrientes

Top-1: "pizza"

clase predicha por el modelo

nutrition_lookup.json

101 categorías · kcal + macros por 100 g · porción típica

factor = porción / 100 g

pizza: 250 g / 100 = 2.5 → cada macro × 2.5

665 kcal · 27.5 g prot · 82.5 g carbs · 25 g grasas

estimación para una porción típica de pizza (250 g)

Fuente: USDA FoodData Central

API pública del gobierno de EEUU. 101 consultas automatizadas con scripts/build_nutrition_lookup.py → JSON de una sola lectura.

Porción fija por categoría

Cada categoría tiene un gramaje típico (pizza=250 g, sushi=180 g). Simplifica el sistema: no necesitamos detectar cuánto hay en el plato.

Limitación principal · mejora futura

El sistema no ve cuánto hay en el plato. Mejora: segmentación + área en píxeles (Clase 6 · Detección de Objetos).

10.6 %

error calórico (MAPE) · meta < 20 %

¿Dónde estamos hoy?

82.86 %

Top-1 accuracy

meta > 80 %

95.83 %

Top-5 accuracy

meta > 92 %

10.6 %

Error calórico (MAPE)

meta < 20 %

Caso de prueba · imagen externa al dataset (bife con papas y huevo)

baby back ribs (38.8%)



Predicciones

1. baby back ribs 38.8%
2. steak 24.0%
3. pork chop 14.1%
4. fish and chips 5.1%
5. prime rib 4.5%

Nutrición (por 100g)

Calorías: 223 kcal
Proteínas: 13.7 g
Carbs: 26.5 g
Grasas: 6.5 g

Porción estimada (~300g)

Calorías totales: 669 kcal

Limitaciones que vemos hoy

1

Confusión entre clases similares

Top-5 ranking todo carne: baby back ribs · steak · pork chop · prime rib. La textura cocida es ambigua.

2

Una sola clase por imagen

El modelo no «ve» las papas fritas — la cabeza emite un único softmax sobre 101 clases.

3

Imagen fuera del dataset

Generaliza, pero confianza baja (38.8 %). Útil para validar robustez con datos reales.

Del clasificador al detector multi-ingrediente

Hoy: 1 clase por imagen + porción fija. Meta: detectar cada alimento, segmentar y estimar gramos por área.

1

Métricas completas

Precision, Recall, F1, curva PR · clasificador

2

Detección multi-alimento

YOLOv8 → bounding boxes · EfficientNet por crop

3

Segmentación con SAM

Máscaras pixel-wise usando los boxes como prompt

4

Porción por área

Plato como referencia de escala → gramos reales

5

Backbone transformer

CLIP / ViT / Grounding DINO open-set

Hilo del informe final → partimos de un clasificador de imagen completa con porción fija, llegamos a un detector multi-ingrediente con estimación de gramos basada en geometría visual.